Compressione

Liceo G.B. Brocchi – Bassano del Grappa (VI)
Liceo Scientifico – opzione scienze applicate
Giovanni Mazzocchin

Compressione

Compressione

Compressione

- **Ridondanza**: presenza di bit deducibili da altri. È possibile rimuovere i bit ridondanti senza perdere informazione
- **Lossless compression**: i dati originali possono essere completamente recuperati da quelli compressi, senza perdita di informazione
- **Lossy compression**: la compressione è irreversibile. I dati originali non possono essere recuperati completamente

Run-length encoding (RLE)

- **Run-length encoding** è una tecnica di compressione lossless nella quale una sequenza di byte uguali (*run*) viene codificata nella forma `count + byte`

- Esempio:

  `AAAABBBBBBBWWWWW -> 4A6B5W`

- Questa tecnica è particolarmente efficiente su dati contenenti molti *run*

- Esercizio: implementare il run-length encoding in Python

Huffman coding (David A. Huffman, 1952)

- Consideriamo dati costituiti da sequenze di caratteri
- Abbiamo bisogno di una tabella contenente la frequenza di ciascun carattere all'interno dei dati da comprimere
- **Esempio**:
  - immaginiamo un file di 1.0E+05 (100 000) caratteri
  - nel testo compaiono soltanto 6 caratteri diversi:
    - `a, b, c, d, e, f`
  - a compare 45 000 volte, b 13 000 volte etc…
  - se usassimo un **fixed-length code** avremmo bisogno di 3 bit per ciascun carattere:
    - con 2 bit codificheremmo 2^2 caratteri, che è < 6
    - con 3 bit codificheremmo 2^3 caratteri, che è > 6

Huffman coding

- 100 000 caratteri, 3 bit per carattere
- Il file peserà 300 000 bit, ossia 37 500 byte, circa 37 kB

can we do better?

Huffman coding

- Già nel XIX secolo, Samuel Morse codificava le lettere più frequenti della lingua inglese con simboli più brevi, arrivando a produrre un **variable-length code**

- La **Teoria dell'informazione** (argomento dell'ultimo anno) fornisce le basi per comprendere nel dettaglio la compressione. Noi cercheremo di introdurre alcuni concetti intuitivamente

Huffman coding

- L'obiettivo è generare un *variable-length code* particolare, detto **prefix code**

- In un **prefix code** vale la seguente condizione:
  - per ogni coppia di simboli ($\mathbf{a_1}$, $\mathbf{a_2}$), se il simbolo $\mathbf{a_1}$ è codificato con la stringa binaria (**codeword**) $\mathbf{c_1}$, e il simbolo $\mathbf{a_2}$ è codificato con la stringa binaria $\mathbf{c_2}$, allora $\mathbf{c_1}$ non è un prefisso di $\mathbf{c_2}$ e $\mathbf{c_2}$ non è un prefisso di $\mathbf{c_1}$

- Vediamo degli esempi

Huffman coding

	a	b	c	d	e	f
frequency (in thousands)	**45**	**13**	**12**	**16**	**9**	**5**
fixed-length codeword	**000**	**001**	**010**	**011**	**100**	**101**
non-prefix, variable-length codeword	**0**	**01**	**011**	**0111**	**01111**	**011111**
prefix, variable-length codeword	**0**	**101**	**100**	**111**	**1101**	**1100**

Huffman coding

	a	b	c	d	e	f
prefix, variable-length codeword	**0**	**101**	**100**	**111**	**1101**	**1100**

- I prefix code sono molto adatti per essere decodificati

- **Esempio)**
  un decodificatore inizia a leggere la stringa seguente da sinistra:

001011101

Huffman coding

	a	b	c	d	e	f
prefix, variable-length codeword	0	101	100	111	1101	1100

001011101

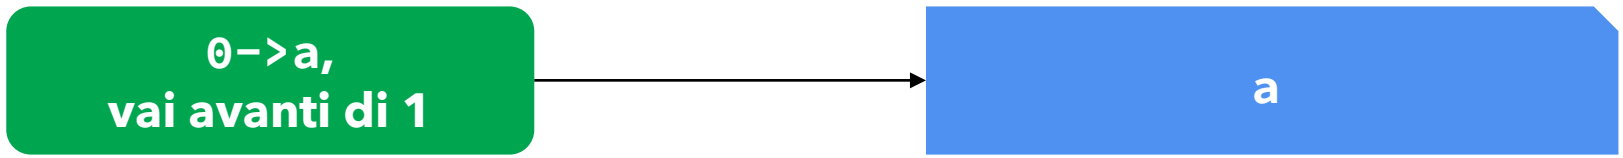

Huffman coding

	a	b	c	d	e	f
prefix, variable-length codeword	0	101	100	111	1101	1100

001011101

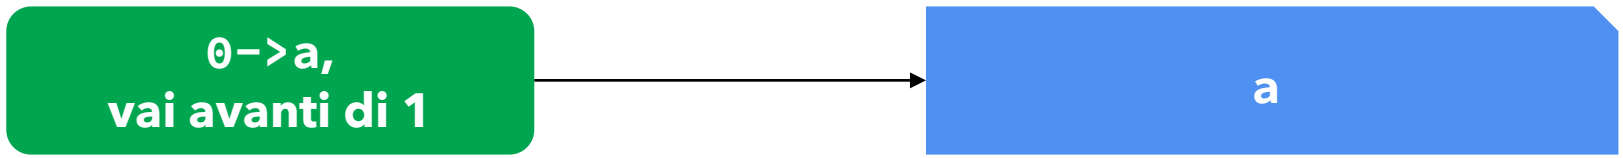

Huffman coding

	a	b	c	d	e	f
prefix, variable-length codeword	0	101	100	111	1101	1100

001011101

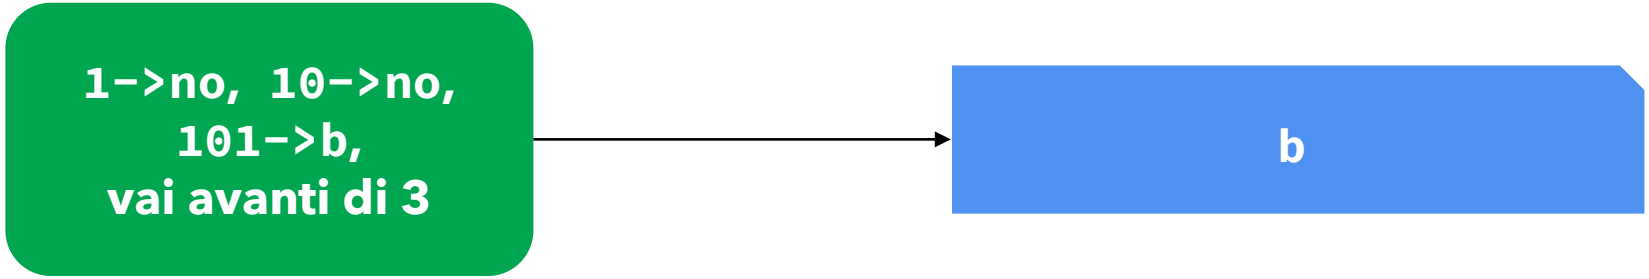

Huffman coding

	a	b	c	d	e	f
prefix, variable-length codeword	0	101	100	111	1101	1100

001011101

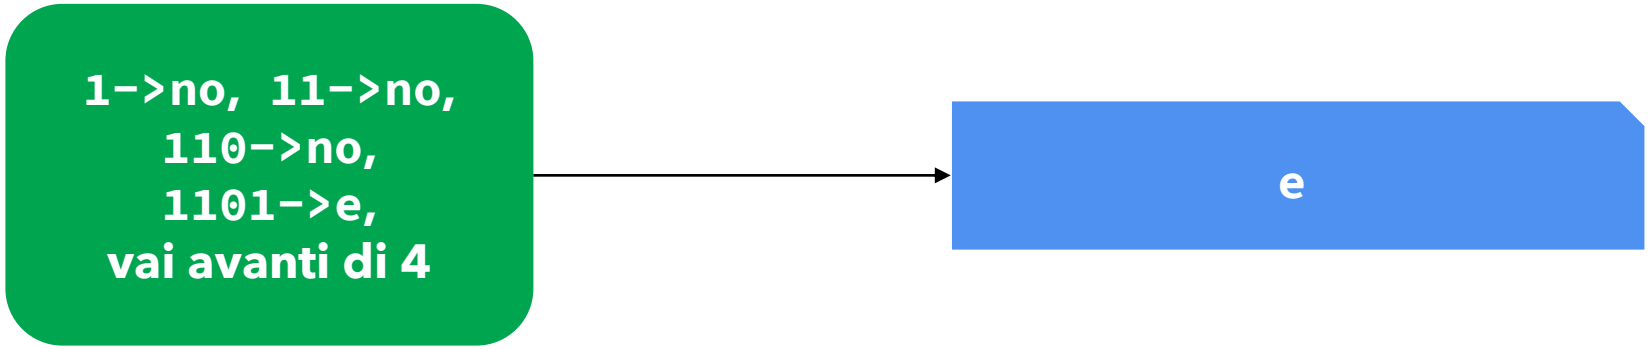

Huffman coding

	a	b	c	d	e	f
prefix, variable-length codeword	0	101	100	111	1101	1100

001011101

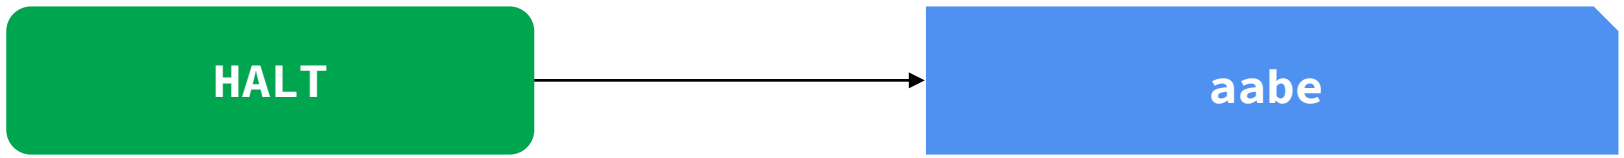

L’algoritmo di Huffman

	f	e	c	b	d	a
frequency	**5**	**9**	**12**	**13**	**16**	**45**

L’**algoritmo di Huffman** permette di generare codici prefissi ottimi

Eccolo descritto in lingua naturale:

iterare le seguenti operazioni fintantoché ci sono caratteri nell’elenco:

1. ordinare l’elenco in senso ascendente in base alla frequenza (passaggio non necessario)
2. considerare i 2 elementi di frequenza più bassa
3. rimuoverli dall’elenco
4. creare un nodo contenente la somma delle frequenze dei 2 elementi estratti, che ha come figli i 2 elementi estratti
5. inserire il nodo creato nell’elenco, con la frequenza calcolata sopra

L’algoritmo di Huffman

	f	e	c	b	d	a
frequency	**5**	**9**	**12**	**13**	**16**	**45**

f: 5 **e: 9** **c: 12** **b: 13** **d: 16** **a: 45**

L’algoritmo di Huffman

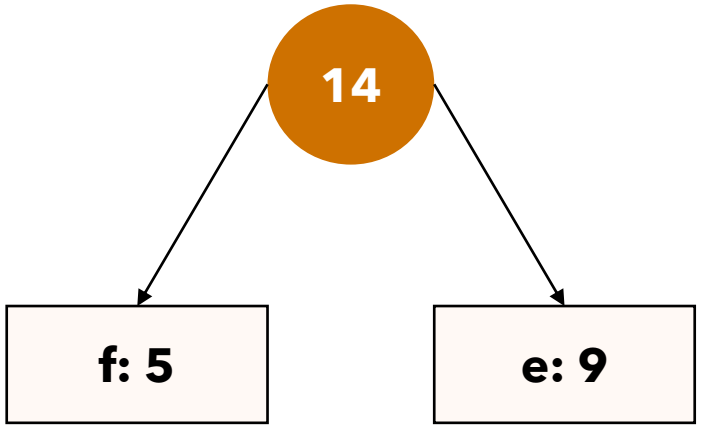

c: 12

b: 13

d: 16

a: 45

L’algoritmo di Huffman

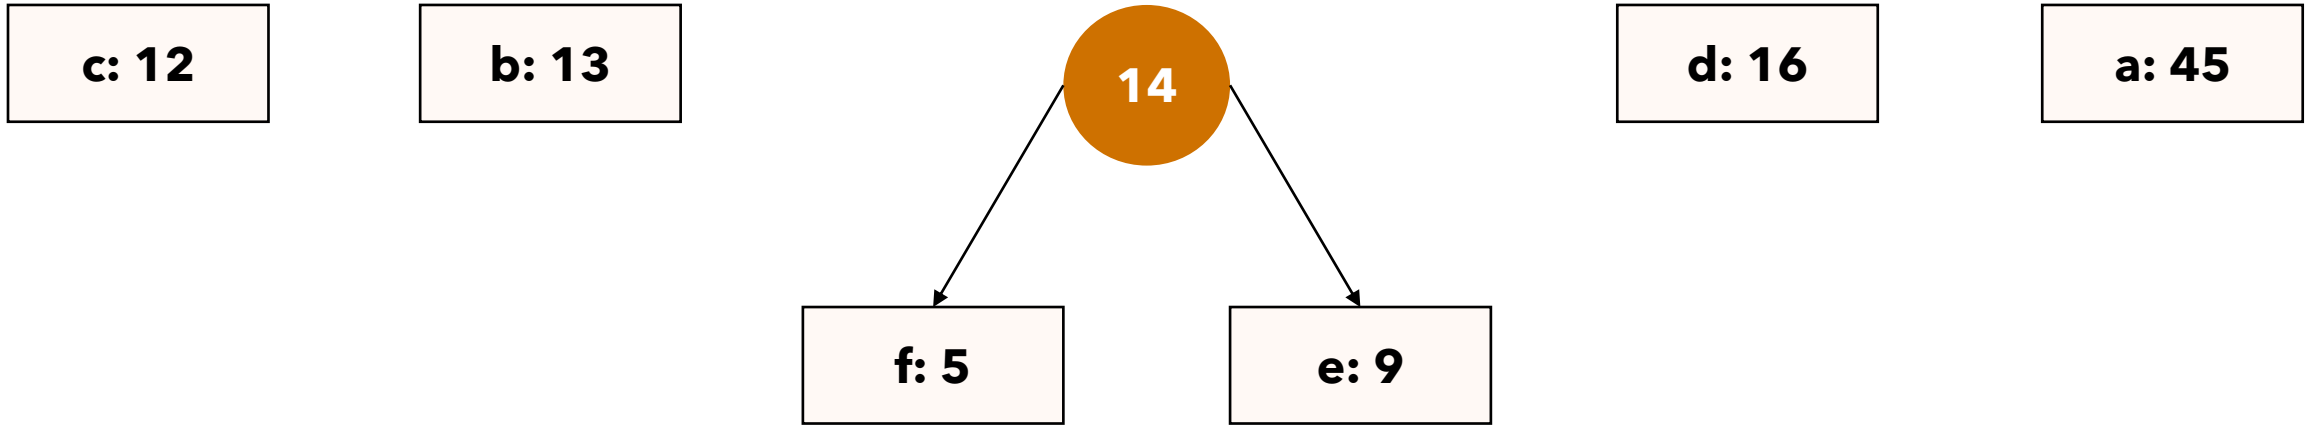

L’algoritmo di Huffman

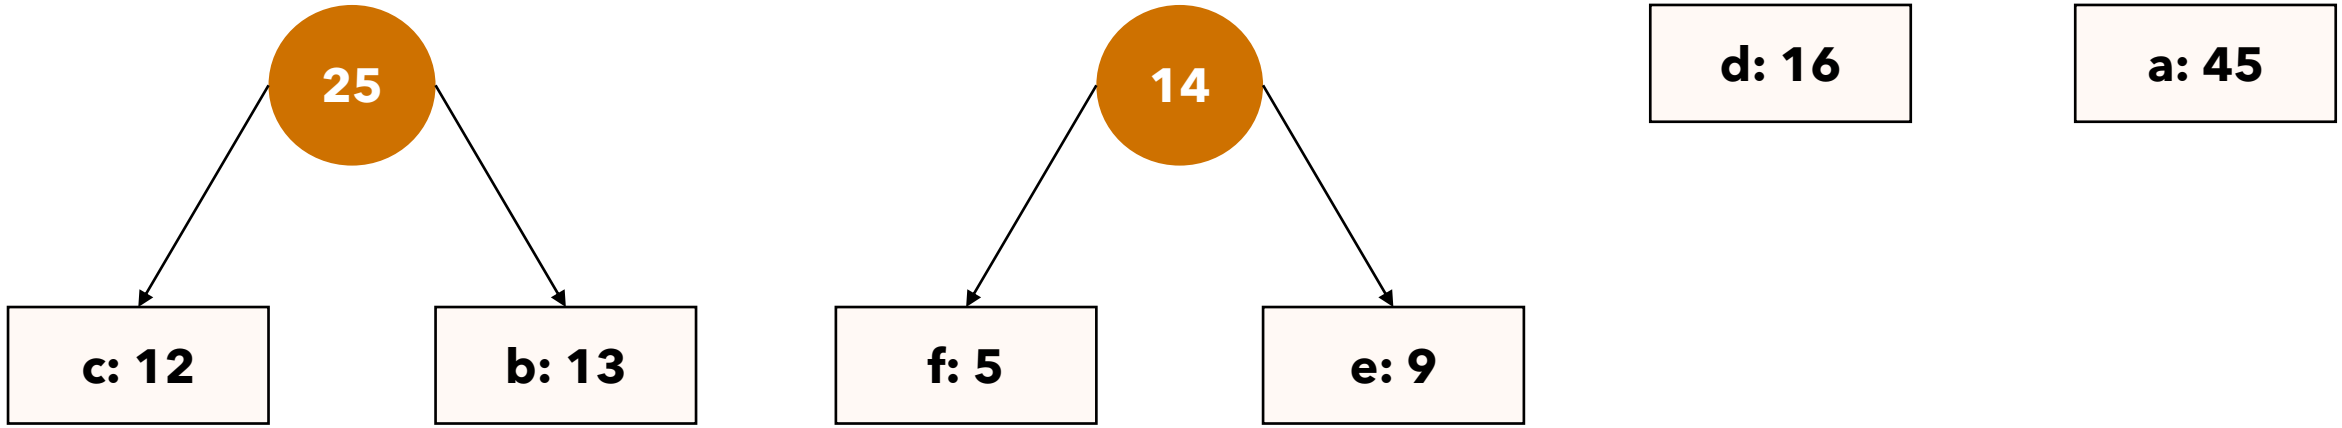

L’algoritmo di Huffman

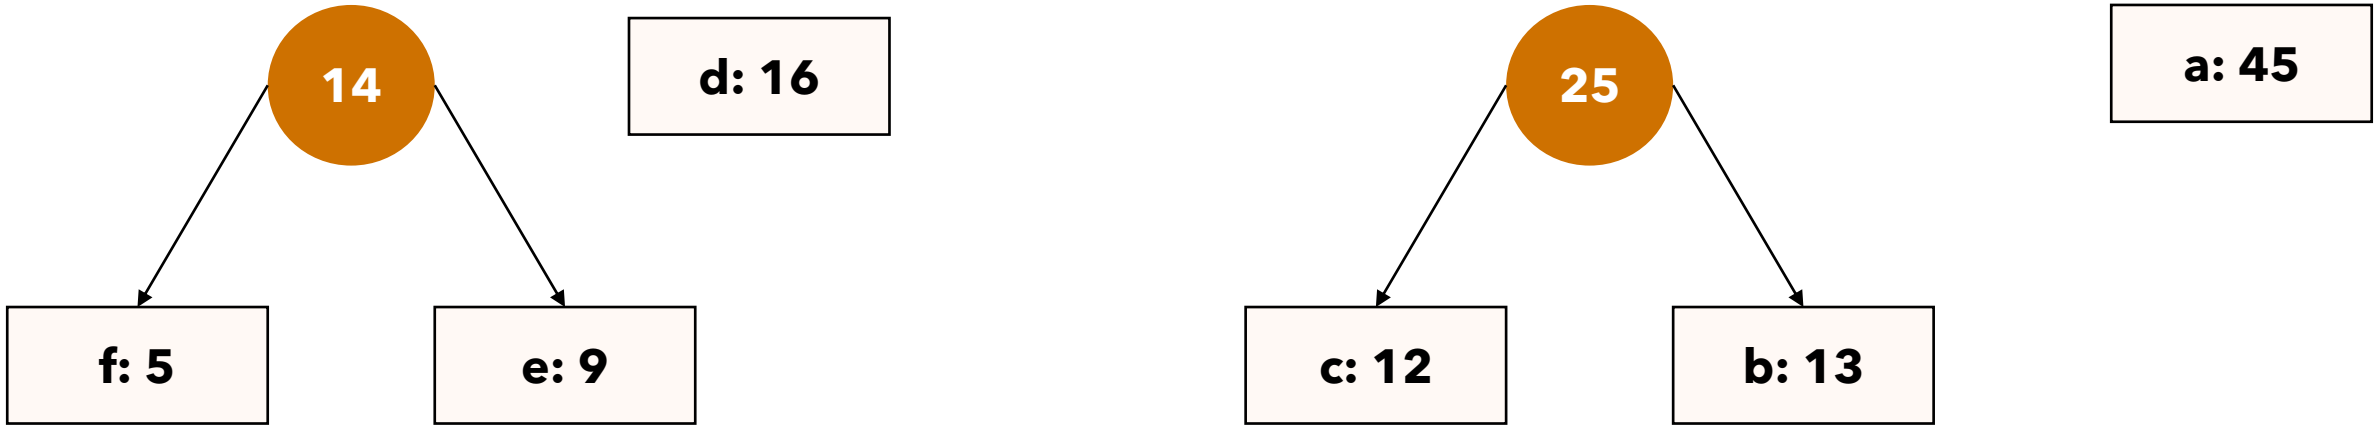

L’algoritmo di Huffman

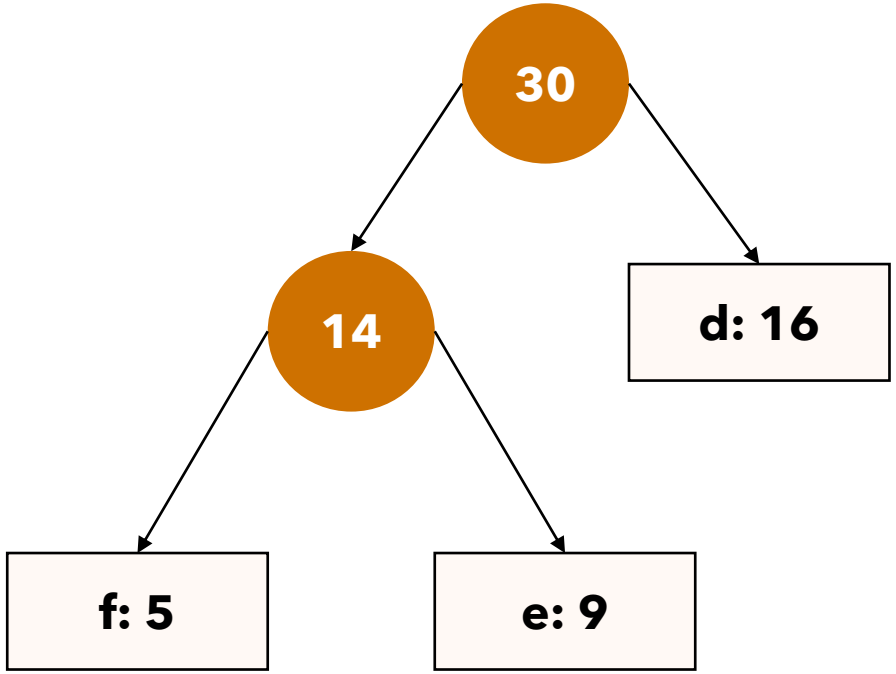

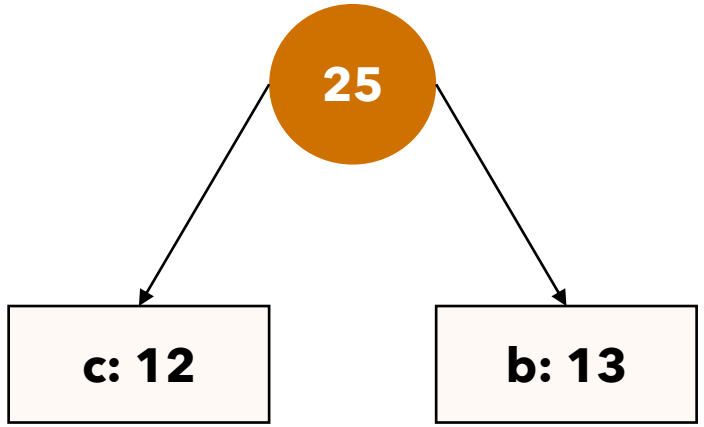

a: 45

L’algoritmo di Huffman

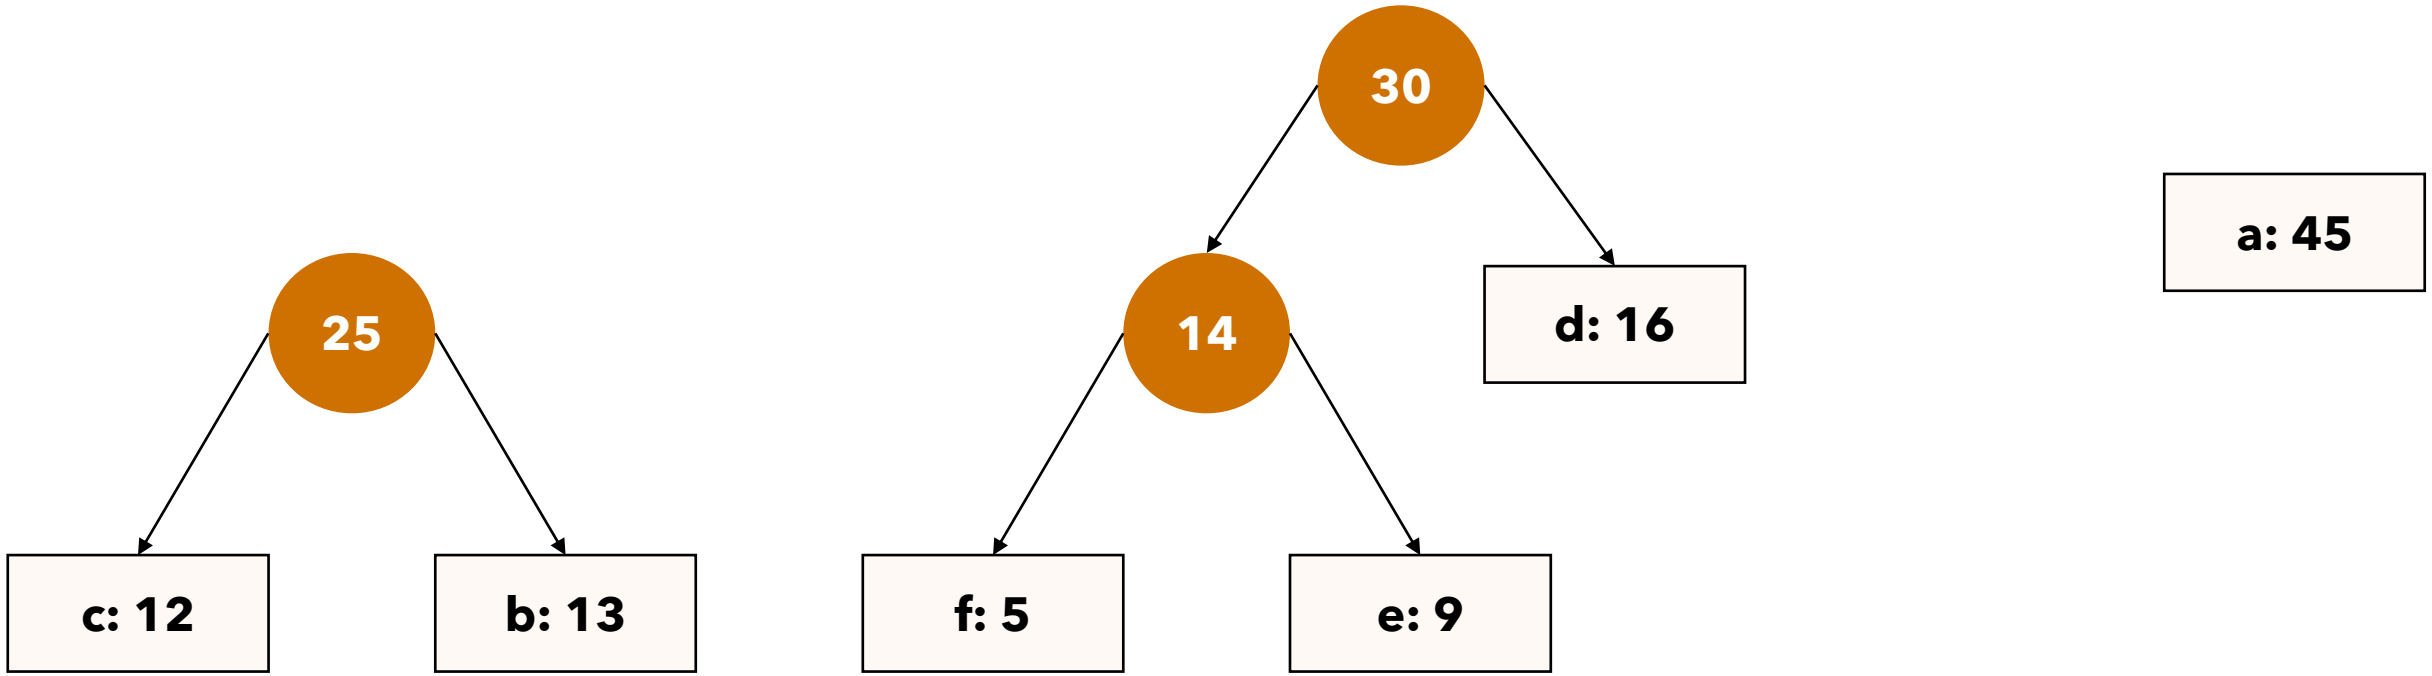

L’algoritmo di Huffman

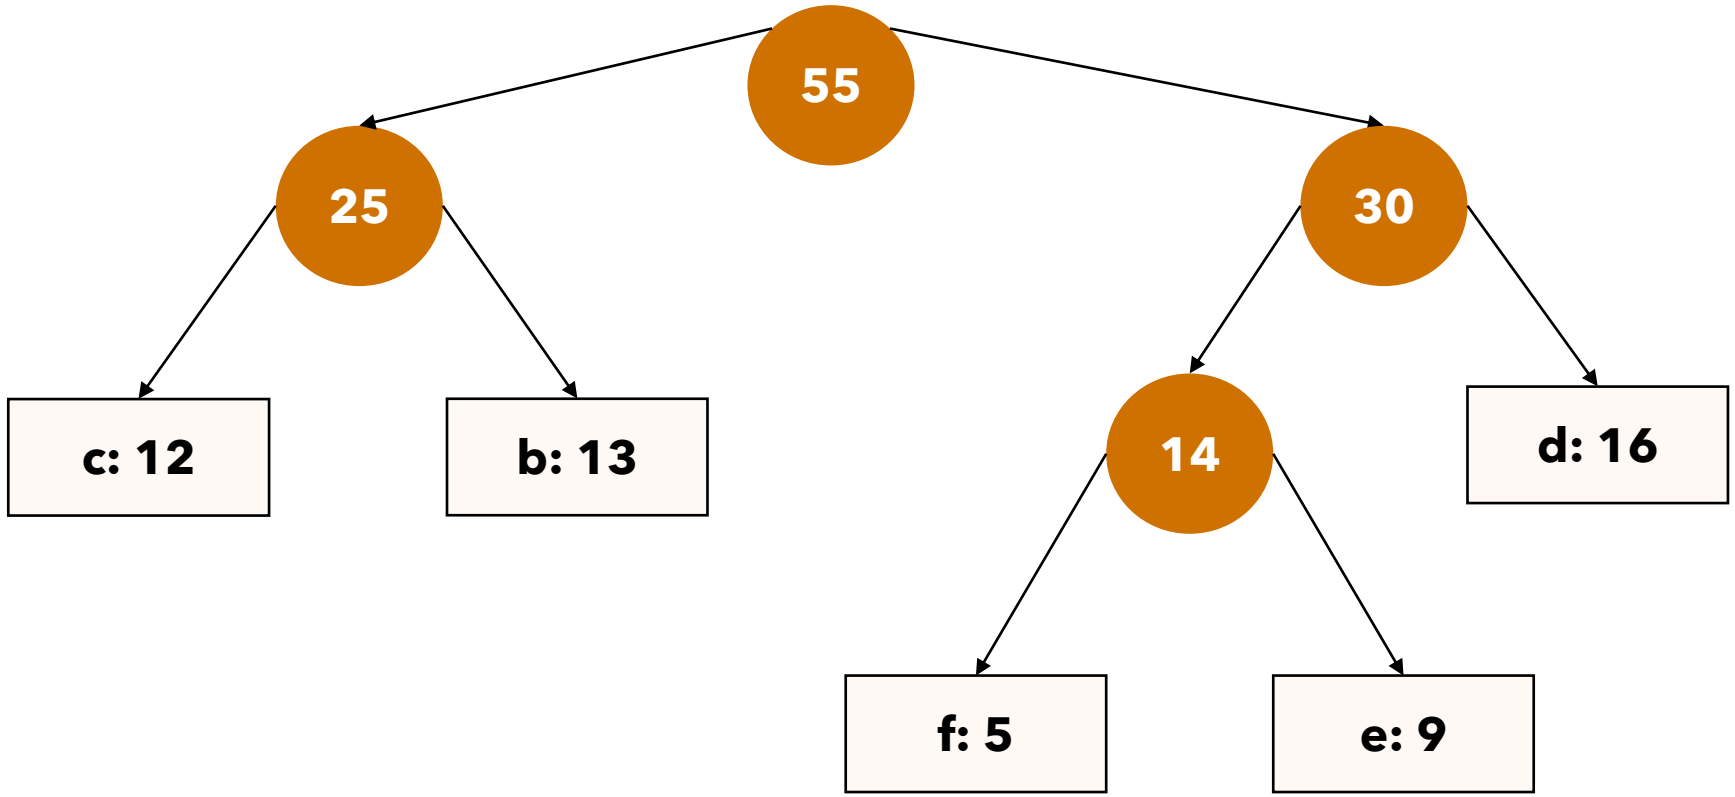

a: 45

L’algoritmo di Huffman

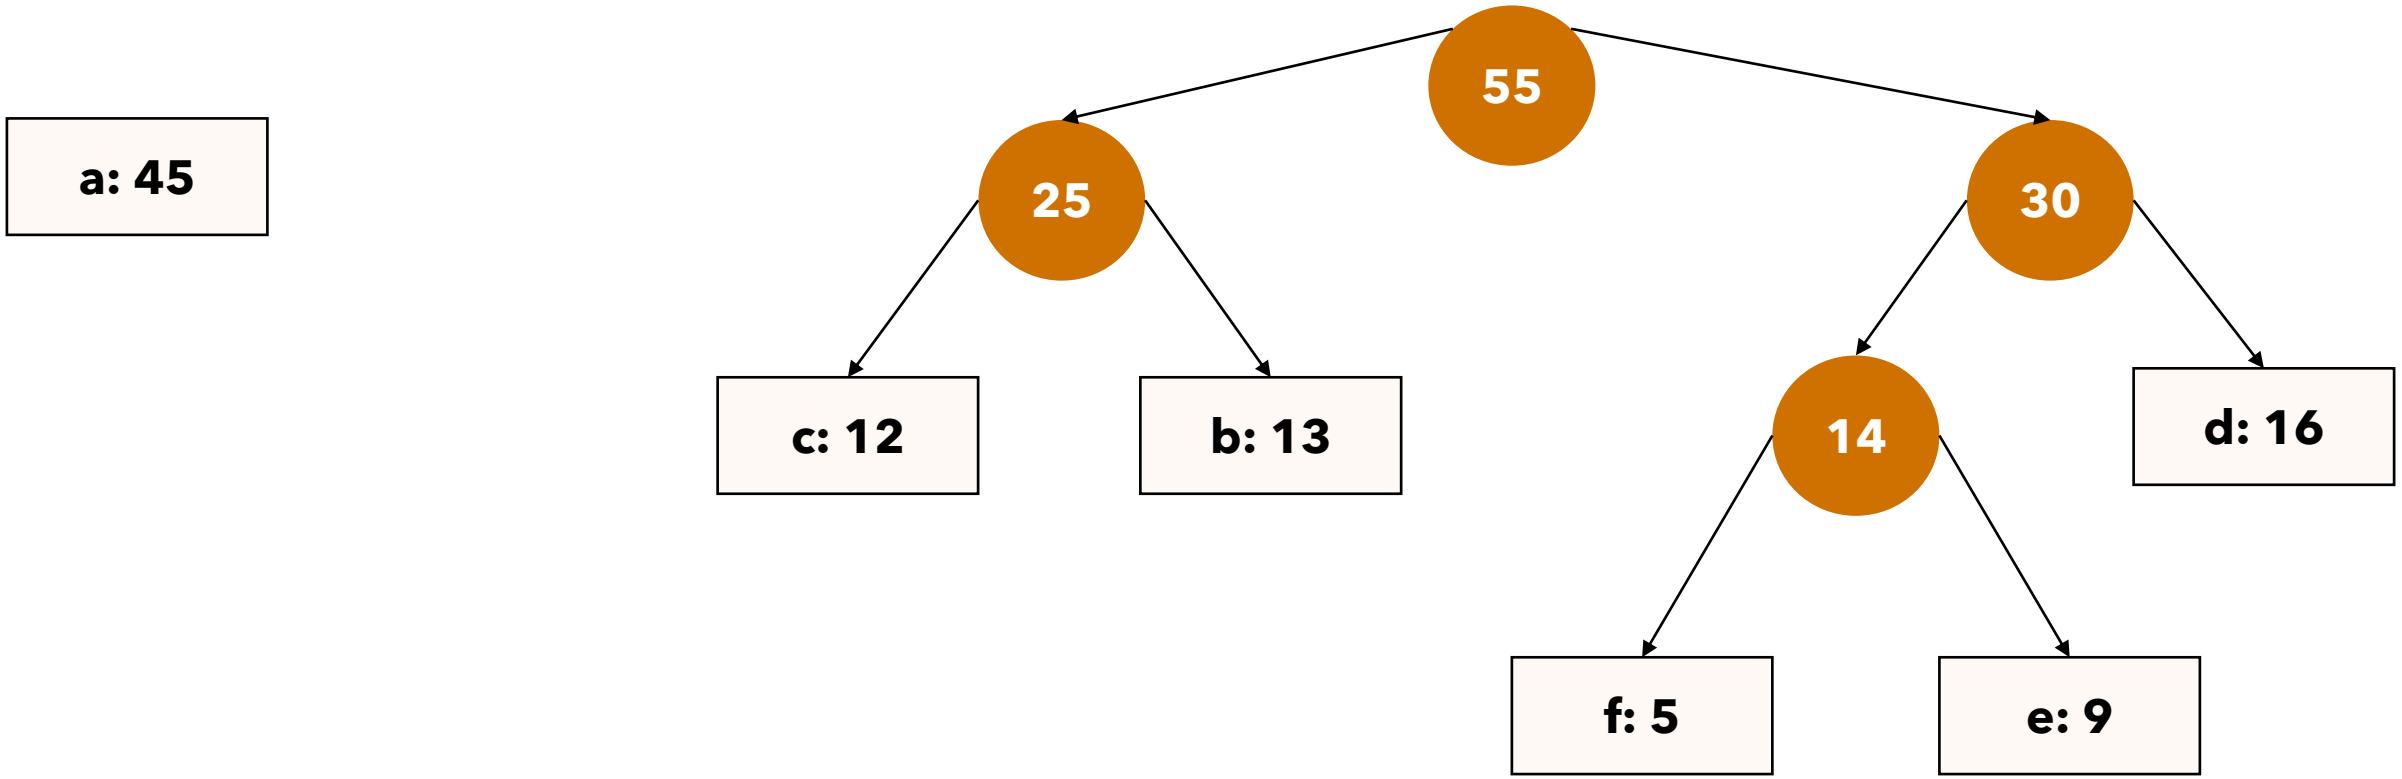

L’algoritmo di Huffman

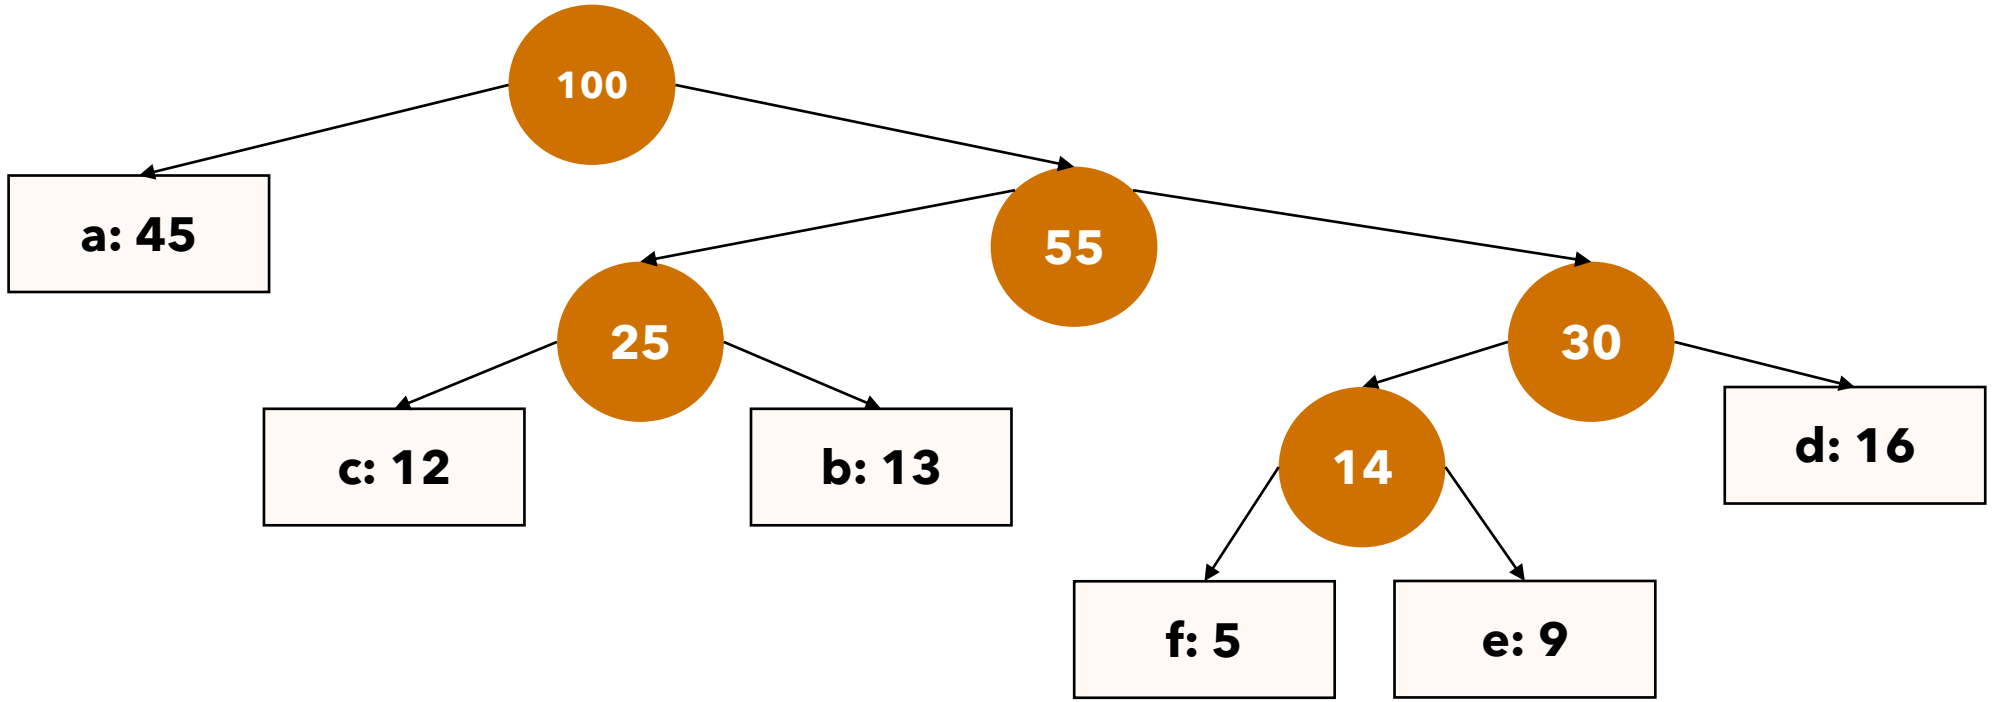

L'algoritmo di Huffman

Il codice di un carattere è prodotto dal percorso dalla radice fino alla foglia corrispondente al carattere stesso. È sufficiente segnare i rami dell'albero così:

- ramo destro: **1**
- ramo sinistro: **0**

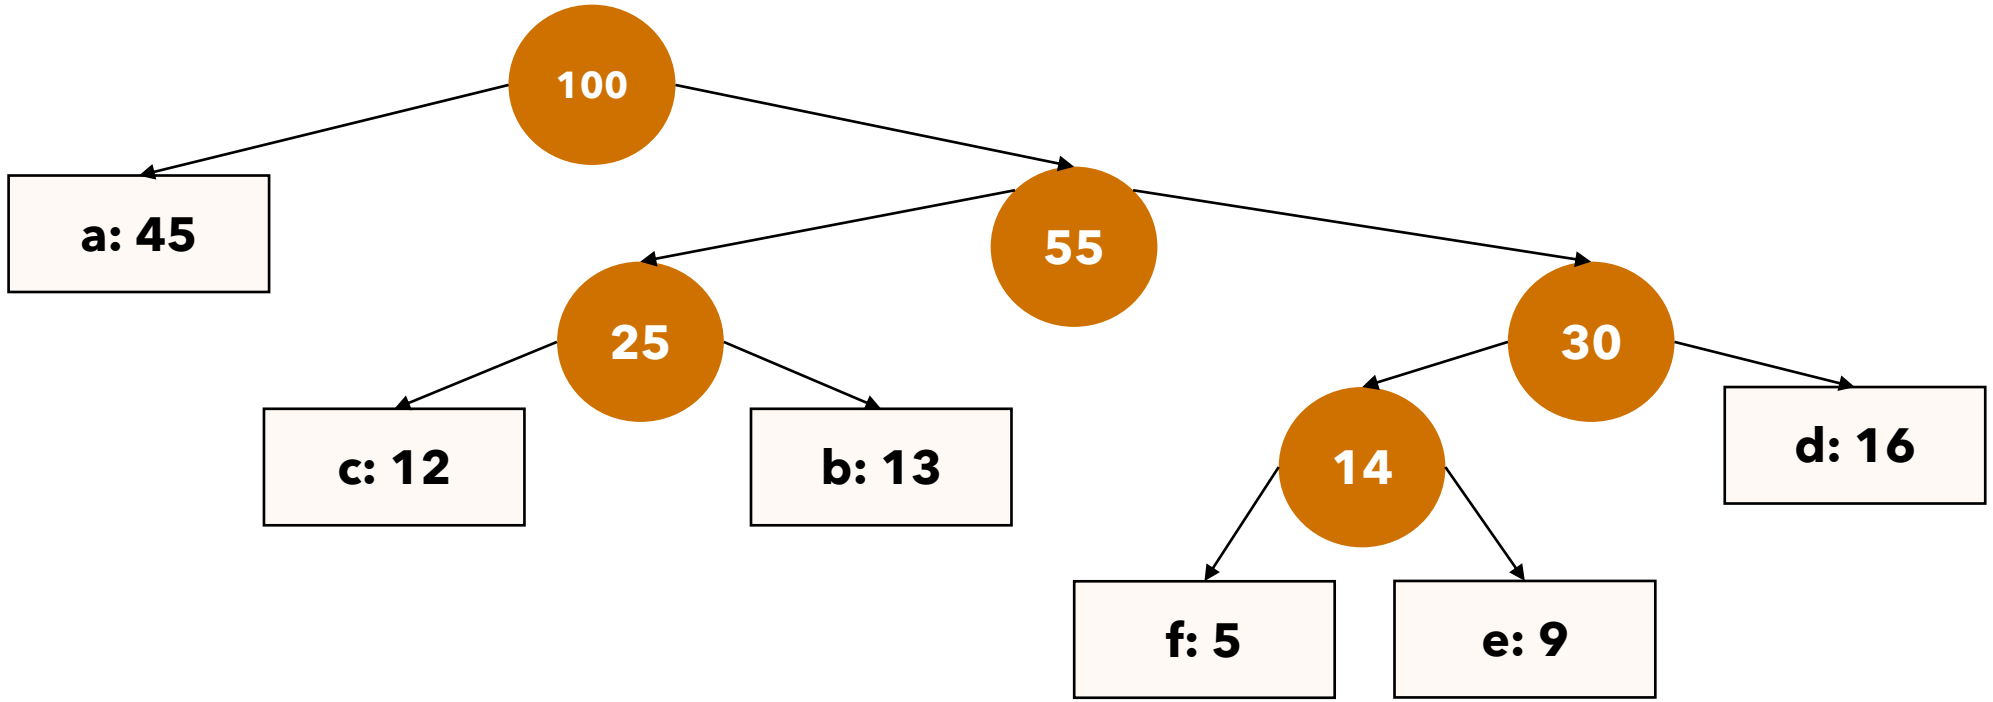

Da vedere/provare a casa

- CMPRSN (Compression Overview) – Computerphile
- Run-length encoding (Python)
- Huffman algorithm (Python)